

Práctico 1 — Análisis y visualización

Decodificando la Ley: clasificación y búsqueda semántica de jurisprudencia argentina

P1 cerrado sobre la muestra oficial (no el corpus de 874k). Defensa pedagógica: [DEFENSA.html](#). Moodle: cuando el buzón acepte.

1. Datos

Se utilizó la **muestra oficial** del repositorio de la mentoría (datos/dataset_sample.jsonl.gz): 8.748 filas × 71 columnas (~1 % del corpus HuggingFace, 874.845 filas). Un censo posterior (véase [validación](#)) muestra que las **tasas estructurales coinciden** (SU/FA, plantilla, dos relojes, sumario≠texto). No coinciden las etiquetas distintas de materia (282 vs 2.636): los porcentajes finos son de la muestra; el relato no se reescribe.

Se excluyeron 1.035 filas de plantilla (sin id-infojus ni materia, descriptores dummy). Quedan **7.713** filas de trabajo. El campo guid es único pero está anonimizado en toda la muestra; no se usa como identificador de caso real.

2. Unidad de análisis

El JSONL no es un único tipo documental. El prefijo de id-infojus y la cobertura de campos distinguen al menos:

Prefijo	n	materia / sumario	tribunal
SU	4.851	sí (~100 %)	no
FA	2.859	no	sí
NV	3	no	no (sí titulo_noticia)

Los faltantes de sumario en FA son **estructurales**, no aleatorios. No se imputa materia en FA.

3. Fueros, tribunales y geografía

No existe la columna fuero. El campo más cercano es materia, presente solo en SU (4.851 valores, 282 categorías). Las más frecuentes son PROCESAL (684), PENAL (527), LABORAL (483), CIVIL (459) y CIVIL - COMERCIAL (419). Hay la misma combinación con otro separador (CIVIL - COMERCIAL, 202).

tipo-tribunal son 139 códigos; el más frecuente es CS (2.877), luego CC (1.048). Provincia: CABA 3.591, Buenos Aires 1.337; el resto cae rápido. Hay desbalance de etiquetas y de geografía: una métrica de accuracy sobre un modelo futuro sería engañosa.

4. Tiempo

Hay más de un reloj. fecha se interpreta como candidato a fecha del documento; 166 filas traen varias fechas separadas por |. timestamp está en milisegundos y, una vez convertido, cubre ~2012–2026 (carga al sistema, no emisión). En 6.606 filas con ambos relojes, solo el **12,4 %** comparte el año; el documento es anterior al timestamp en todos esos casos. Un pico de timestamp no se interpreta como volumen de fallos emitidos.

5. Variable objetivo (preliminar)

El proyecto pide predecir fuero/rama a partir del sumario. Se identifica materia en filas SU como **candidato** a origen de esa etiqueta. No se congela la receta de colapso en este práctico: materia mezcla fueros con tipos procesales, combinaciones y 891 valores sin token típico de fuero. Los FA no tienen materia.

Si el target se deriva de materia, no se usarán materia ni descriptores equivalentes como features en la etapa supervisada, coherente con “predecir leyendo exclusivamente el sumario”.

6. Textos

En SU coexisten dos campos que **no son el mismo contenido**. sumario es un encabezado corto (mediana 73 caracteres; 100 % con markup [[p]]). texto es el párrafo (mediana 509 caracteres). Igualdad exacta: 0 %. Se elige texto en SU para el análisis léxico. Los FA no traen estos campos. No se concatenan campos. No se analizan fallos completos.




Figura 1. El nombre de la columna “sumario” no coincide con un sumario en sentido prosa.

Vocabulario de texto ~21.700 tipos. Términos frecuentes (sin stopwords genéricas de castellano): jerga procesal transversal (*recurso, sentencia, prueba*), no un fuero. Bigramas: recurso extraordinario, daños y perjuicios, contrato de trabajo.




Figura 2. Frecuente no es distintivo.




Figura 3. Locuciones que un tokenizador unigram rompe.

Agrupando de forma **provisoria** por un único token de fuera en materia (Y no cerrada), el párrafo de PENAL / CIVIL / LABORAL muestra léxico distintivo. CIVIL-only 714, COMERCIAL-only 275,

ambas etiquetas 689: frontera difusa. No se congela el target.




Figura 4. Distintivo vs resto; agrupación no es la etiqueta final.

7. Validación vs corpus completo

Se contrastó la muestra con el JSONL completo (874.845), un SRS de 8.748 y un estratificado por prefijo. Tasas SU/FA/plantilla y el hecho sumario≠texto coinciden (TVD de prefijos 0,002). materia distinta: 282 vs 2.636 etiquetas. Informe: [VALIDACION.html](#). P2 no usará 8.7k como universo de clases.

8. Limitaciones y riesgos para P2

- Muestra, no censo.
- Dos unidades (SU/FA). No imputar materia en FA.
- Target no cerrado. No usar materia, descriptores ni el encabezado sumario como feature si Y nace de materia.
- No ajustar representaciones con el test. $CIVIL \cap COMERCIAL$ es clase gris.
- Uso académico; no es asesoramiento jurídico.

Fuente de datos: SAIJ vía dataset Apache 2.0 de marianbasti. Cálculos: `practicos/P1/p1_edu.ipynb`.