

Práctico 2 — Exploración y curación

Hasta **D5** (Y grosera). D6 clustering todavía no. Defensa §9: [DEFENSA.html](#).

1. Datos de trabajo

No se reutiliza la muestra 8.748 de P1 como universo. Se extrae del JSONL completo (874.845) un reservoir estratificado SU+FA, seed 42: **31.400 SU + 18.600 FA**. Motivación P1: 282 vs 2.636 etiquetas de **materia**. En estas 50k SU hay 725 materias crudas (567 normalizando guiones).

2. Limpieza

- Ids únicos; 27 textos SU repetidos (pendiente: no partir el mismo párrafo train/test).
- FA sin **texto**: fuera del pipeline NLP de fuera.
- **materia**: solo unificación -/espacios. Sin fuzzy ni lista canónica.

3. Variables

Uso	Campos
X	texto en SU
Y (D5)	tokens canónicos en materia ; no es feature
Split	fecha → year; train < 2013 (24.645) / test ≥ 2013 (6.755)
Prohibidos como X si Y=fuero	materia, sumario-encabezado, descriptores, provincia, tribunal

4. Representación (D4)

Bake-off interno (vectorizer fit en SU year<2010; validación 2010–2012; test ≥2013 no usado). Etiqueta sonda: un solo token de fuera en materia (no es Y final).

Representación	macro-F1 sonda
Dummy estratificado	0,171
BoW + NB / LR	0,645 / 0,647
TF-IDF + NB	0,634
TF-IDF + LR	0,681 (elegida)
LSA (TF-IDF+SVD 128) + LR	0,606

Congelado: TF-IDF 1–2 grams, min_df=5, 8.000 features, stopwords genéricas, sin lemas. Embeddings neuronales no corridos. BoW queda de baseline.

5. Etiqueta Y (D5)

Sin fuzzy. Sobre **materia** con guiones unificados:

1. Intersección con {CIVIL, COMERCIAL, PENAL, LABORAL, ADMINISTRATIVO, CONSTITUCIONAL}.
2. Exactamente {CIVIL, COMERCIAL} → **CIVIL-COMERCIAL**.
3. Exactamente un token → esa clase.
4. Cero o cualquier otro combo → **OTROS**.

Y (31.400 SU)	n
OTROS	7726
PENAL	5282
CIVIL-COMERCIAL	4168
CIVIL	4018
LABORAL	3235
CONSTITUCIONAL	2832
ADMINISTRATIVO	2514
COMERCIAL	1625

OTROS (~25 %) no es un fuero: es “la regla no aplicó”. El F1 0,68 de D4 usaba solo exclusivos; no es el de P3.